

Euron Week11 학습 내용 요약

주제: 희소 행렬(Sparse Matrix) 변환 및 규칙/어휘 사전 기반 감성 분석(Sentiment Analysis)

1. 희소 행렬(Sparse Matrix) 자원 압축 및 변환 기술

텍스트 마이닝 및 대규모 데이터 분석 환경에서는 행렬의 대부분 원소가 0으로 채워진 희소 행렬(Sparse Matrix) 구조가 빈번하게 발생합니다. 이러한 데이터 구조는 불필요한 메모리 낭비를 유발하므로, 연산 효율성을 극대화하기 위해 이를 효과적으로 압축하는 두 가지 핵심 포맷인 COO와 CSR 형식을 실습했습니다.

1.1 COO(Coordinate) 형식 압축

COO 형식은 0이 아닌 실제 데이터 값들과, 해당 데이터가 위치한 행(Row) 및 열(Column)의 좌표 인덱스를 각각 별도의 배열(Array)로 독립적으로 저장하는 방식입니다. 대형 행렬의 초기 구조화 단계에서 직관적으로 활용됩니다.

1.2 CSR(Compressed Sparse Row) 형식 압축

CSR 형식은 COO 방식에서 발생하는 행 위치 배열의 중복 항목을 제거하여, 행 좌표의 시작 위치 인덱스(Row Position Index)만을 관리하는 방식입니다. 행 단위 연산 속도를 대폭 향상시키며 고차원 텍스트 피처 벡터화 데이터 압축에 최적화되어 있습니다.

2. 지도학습 기반 감성 분석 및 파이프라인(Pipeline) 설계

IMDB 영화 리뷰 데이터 세트(labeledTrainData.tsv)를 활용하여 텍스트 정제 전처리를 거친 뒤, 카운트 피처 벡터화와 로지스틱 회귀 모델을 유기적으로 결합한 파이프라인(Pipeline) 분류 체계를 구축했습니다.

2.1 정규 표현식 기반 텍스트 정제

문서 내 포함된 불필요한 HTML 태그(
)를 문자열 replace 함수로 제거하고, 파이썬 정규 표현식 모듈(re)을 이용해 알파벳을 제외한 특수문자 및 숫자를 모두 공백으로 일괄 변환하여 노이즈를 제어했습니다.

2.2 엔드투엔드 파이프라인 구축 및 평가

Scikit-learn의 Pipeline 객체를 사용하여 텍스트 데이터의 Count 피처 벡터화와 로지스틱 회귀(Logistic Regression) 분류 알고리즘을 단일 프로세스로 결합했습니다. 검증 데이터를 통해 모델의 최종 성능 지표인 정확도(Accuracy)와 ROC-AUC 수치를 연산하여 정량적 분류 정확성을 검증했습니다.

3. Lexicon(어휘 사전) 및 자연어 처리 기술 기반 감성 분석

별도의 대규모 지도학습 모델 훈련 없이, 텍스트 자체에 내포된 주관적인 감정을 판별하기 위해 NLTK 패키지의 어휘 사전 알고리즘을 설계하고 활용했습니다.

3.1 WordNet 의미 분석 및 유사도 계산

단어가 가진 고유한 어휘적 의미 집합인 시넷(Synset) 객체를 통해 다의어와 동음이의어의 품사(POS), 사전적 개념 정의(Definition), 표제어(Lemmas) 정보를 분석했습니다. 또한 path_similarity() 함수를 연계하여 주요 명사 시넷 간의 문맥적 경로 유사도를 연산하고 판다스 데이터프레임 구조로 시각화했습니다.

3.2 SentiWordNet 기반 감성 극성(Polarity) 연산

NLTK 품사 태깅(pos_tag)의 Penn Treebank 형식을 WordNet 호환 품사 식별자로 변환하는 커스텀 함수를 구축했습니다. 추출된 단어 어근(Lemma)을 기반으로 감성 시넷(SentiSynset)을 도출하고, 모든 단어의 긍정 지수(Positive Score)와 부정 지수(Negative Score)의 차를 누적 합산하여 문장의 최종 감성 극성을 이진 분류(0 또는 1)하는 로직을 구체화했습니다.

3.3 VADER 감성 분석 모델링 및 성능 검증

소셜 미디어 및 정형화되지 않은 텍스트 문맥 분석에 특화된 VADER SentimentIntensityAnalyzer 객체를 연동했습니다. 복합 감성 지수인 compound 스코어가 설정한 임계값(Threshold = 0.1) 이상일 때 긍정으로 판단하는 예측 분류를 수행했으며, 실제 정답 배열과 비교하여 오차 행렬(Confusion Matrix), 정확도, 정밀도, 재현율 성능 지표를 도출하여 모델링을 성공적으로 마무리했습니다.

4. 실습 분석 알고리즘별 성능 평가 분석 요약

감성 분석 방법론 (Methodology)	주요 분석 메커니즘 (Mechanism)	평가 대상 지표 (Metrics)
SentiWordNet 규칙 기반 분석	품사 태깅 및 어근 추출 연계, 단어별 긍정/부정 지수 가감 플로우 연산	오차 행렬, 정확도(Accuracy), 정밀도(Precision), 재현율(Recall)
VADER 규칙 기반 분석	특화 어휘 사전을 통한 속성별 점수 매핑, Compound 지수 임계값(0.1) 이진 분류	오차 행렬, 정확도(Accuracy), 정밀도(Precision), 재현율(Recall)